딥러닝 프로그래밍 실습 #1

공공자전거 대여량 예측 : MLP 회귀 모델링과 과적합 방지 실험

Public Bike System 데이터셋을 활용한 딥러닝 회귀 실습 — 전처리 , 기본 MLP, Dropout/EarlyStopping, 손실함수 비교

윤성근

동료 대학생 대상 보고서 · 2026. 9. 15

1. 데이터셋 개요

Public Bike System 데이터셋 구조

1 시간 단위로 기록된 공공자전거 대여량 + 기상 / 달력 정보

8,760 건

표본 수
(1 시간 단위 × 1 년)

13 개

특성 (feature) 수
날짜 · 시간 · 기상 7 종 · 계절 · 공휴일 · 운영일

회귀

문제 유형
Rented Bike Count (연속형) 예측

특성 (feature) 상세 — 13 개

범주형 (3)	Seasons(4 계절), Holiday(공휴일 여부), Functioning Day(운영일 여부)
날짜 / 시간 (2)	Date → Month 파생 , Hour(0~23 시)
기상 수치형 (7)	Temperature, Humidity, Wind speed, Visibility, Dew point temperature, Solar Radiation, Rainfall, Snowfall

목표변수 : Rented Bike Count (해당 시간대 대여된 자전거 수) · 문제 유형 : 회귀 (구간화 시 분류로 전환 가능)

1. 데이터셋 개요

데이터 전처리 & 목표변수 분포

① **원 - 핫 인코딩**

Seasons·Holiday·Functioning Day → 18 개 특성으로 확장

② **정규화 (StandardScaler)**

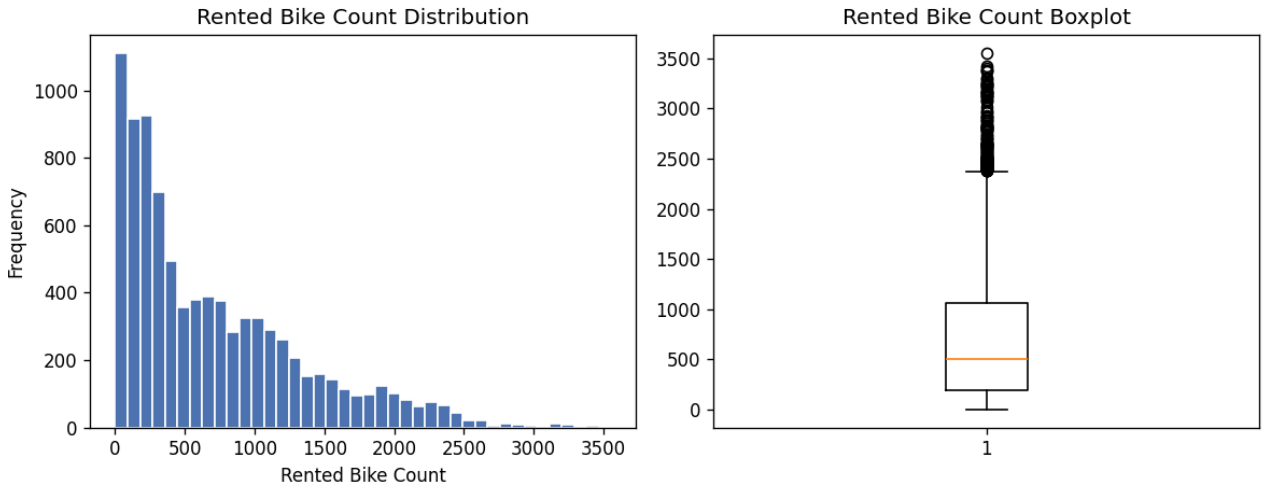
수치형 9 종 + 목표변수 (대여량) 를 표준화 → 학습 안정성 확보

③ **train/test 분할**

8:2 비율 (train 7,008 건 / test 1,752 건), random_state 고정

④ **목표변수 분포 확인**

0~3,556 범위 , 오른쪽으로 치우친 분포 (skewness ≈ 1.15)

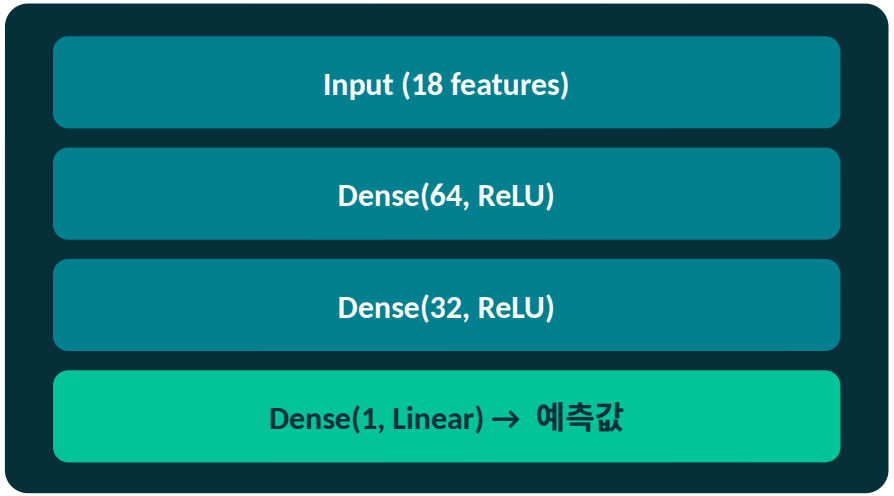


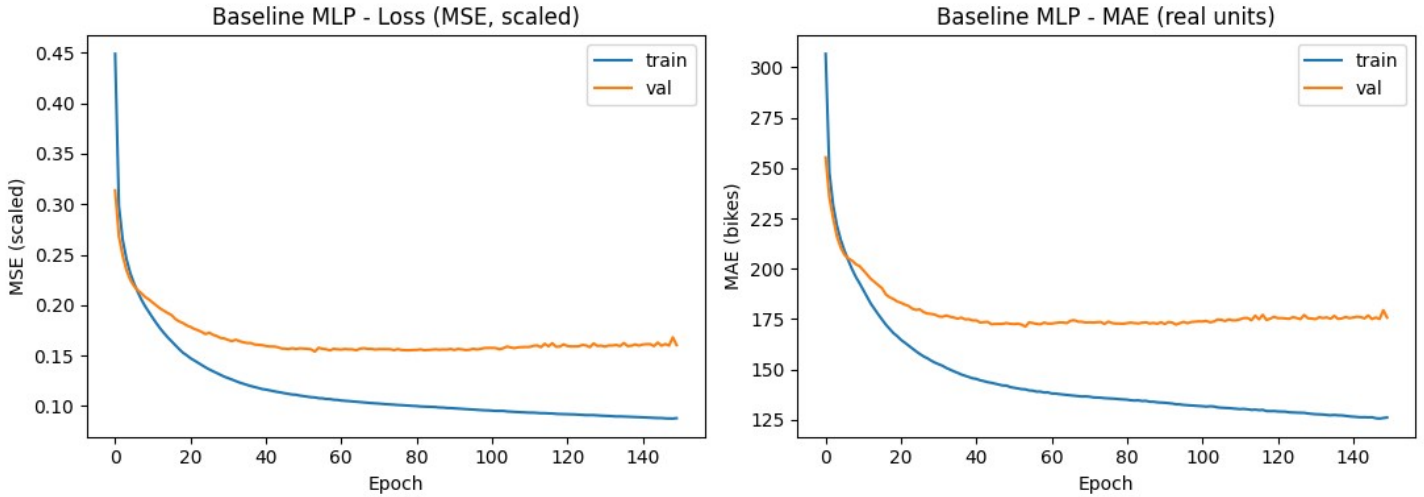
관찰 : 대여량은 0 근처에 몰려있고 오른쪽 꼬리가 긴 비대칭 분포 . 평균 704.6 건 , 표준편차 645.0 건으로 변동성이 큼 → 목표변수도 정규화하여 학습 수렴 속도를 개선함 .

2. 기본 모델

기본 MLP 회귀 모델 구축

은닉층 2 개 · 손실함수 MSE · 평가지표 MAE





optimizer = Adam
loss = MSE (Mean Squared Error)
metric = MAE (Mean Absolute Error)
epochs = 150, batch size = 32

학습 곡선 관찰 : train loss 는 계속 감소하지만 val loss 는 약 54 epoch 이후 정체 · 미세 반등 → 과적합 신호 .
Test MAE ≈ 172.6 건 , Test RMSE ≈ 259.2 건 (150 epoch 학습 후).

2. 기본 모델 및 과적합 방지

과적합 방지 기법 적용

Dropout(0.2) + EarlyStopping 콜백 추가

Dense(64, ReLU)

Dropout(0.2)

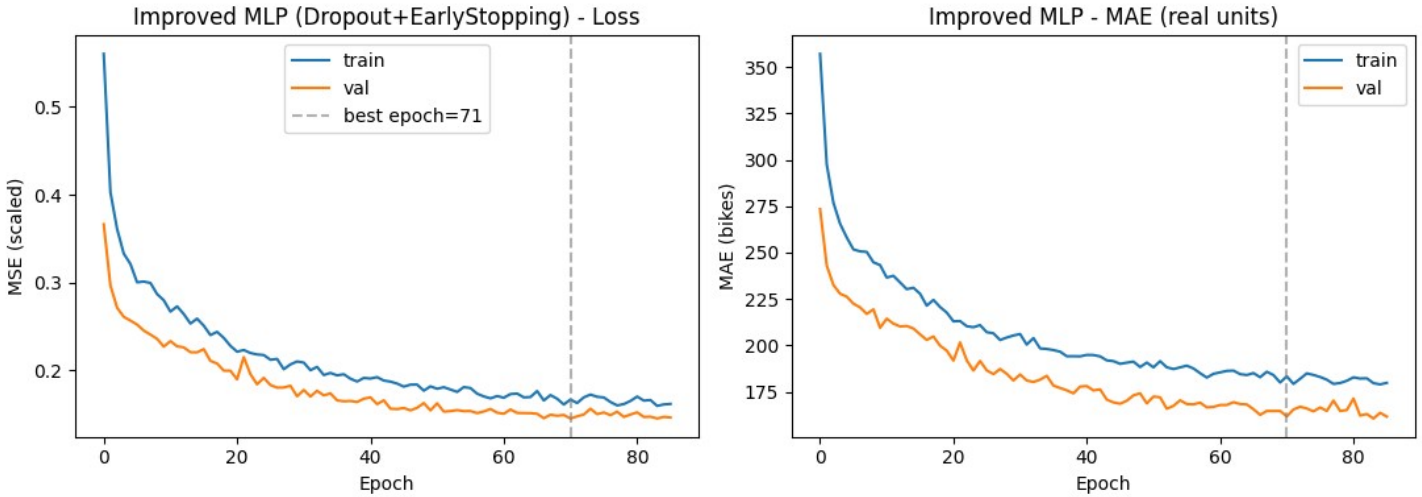
Dense(32, ReLU)

Dropout(0.2)

Dense(1, Linear)

EarlyStopping

monitor='val_loss', patience=15,
restore_best_weights=True

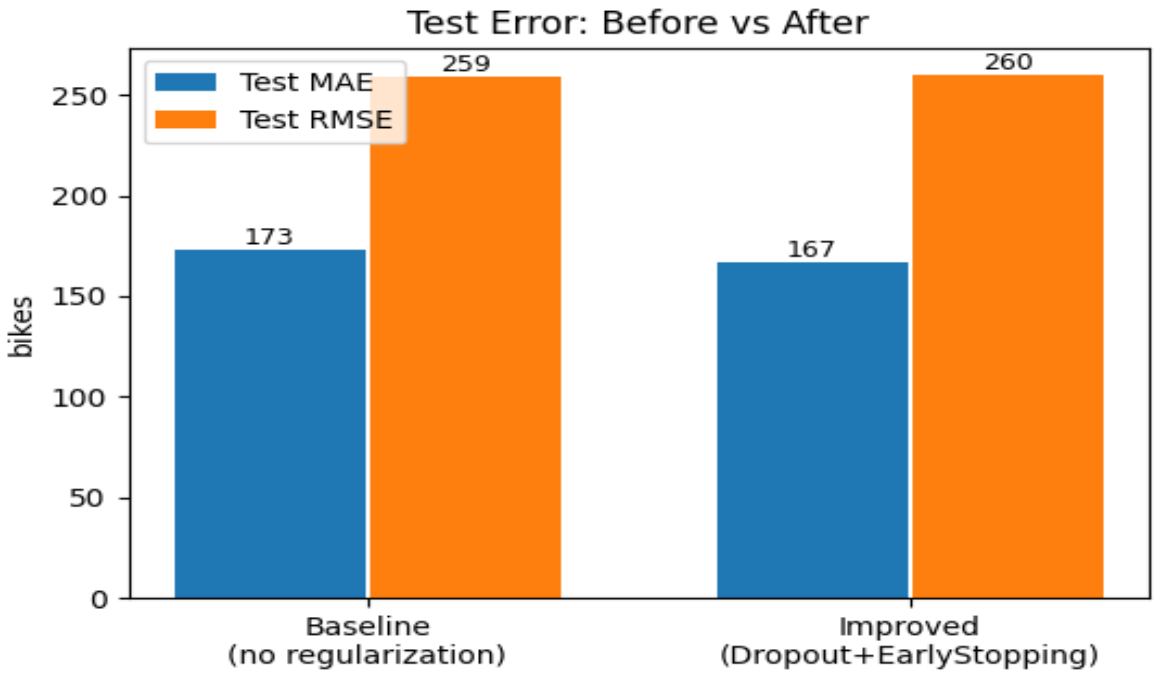


EarlyStopping 결과 : 최대 150 epoch 중 86 epoch 에서 학습 중단 (최적 시점은 71 epoch, 이후 15 epoch 개선 없어 종료). 가중치는 best epoch(71) 기준으로 복원 .

Test MAE ≈ 166.7 건 , Test RMSE ≈ 260.0 건 — baseline 대비 MAE 약 3.4% 개선 .

2. 과적합 방지 비교

적용 전 (Baseline) vs 적용 후 (Dropout+EarlyStopping) 비교



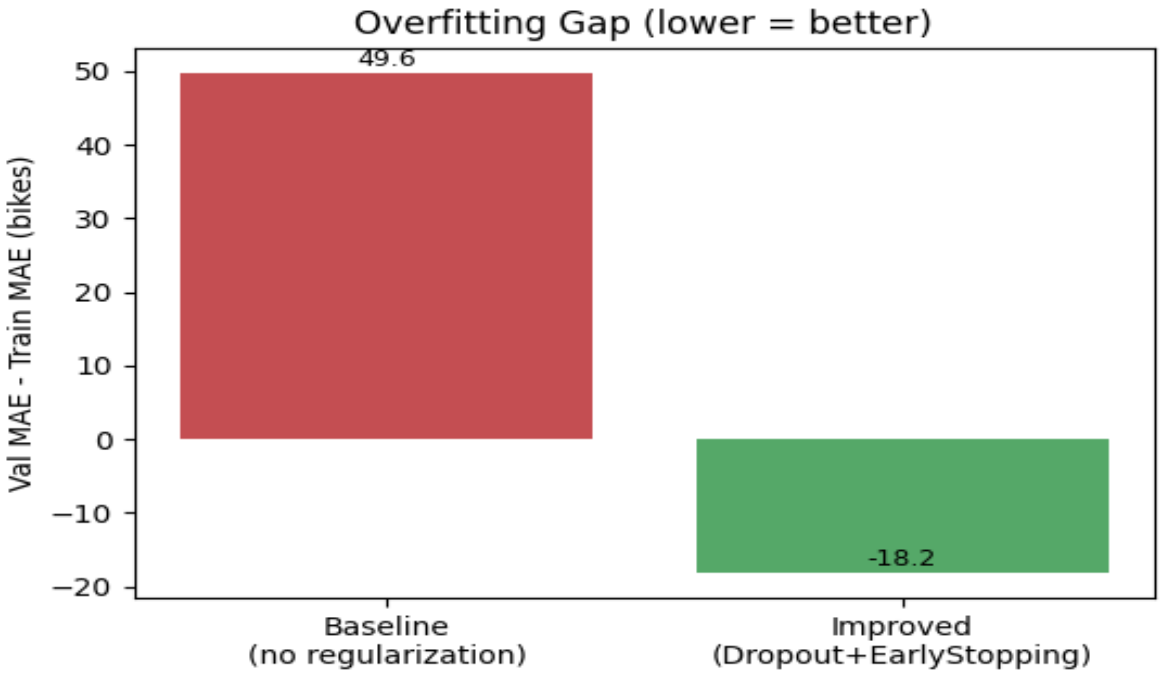


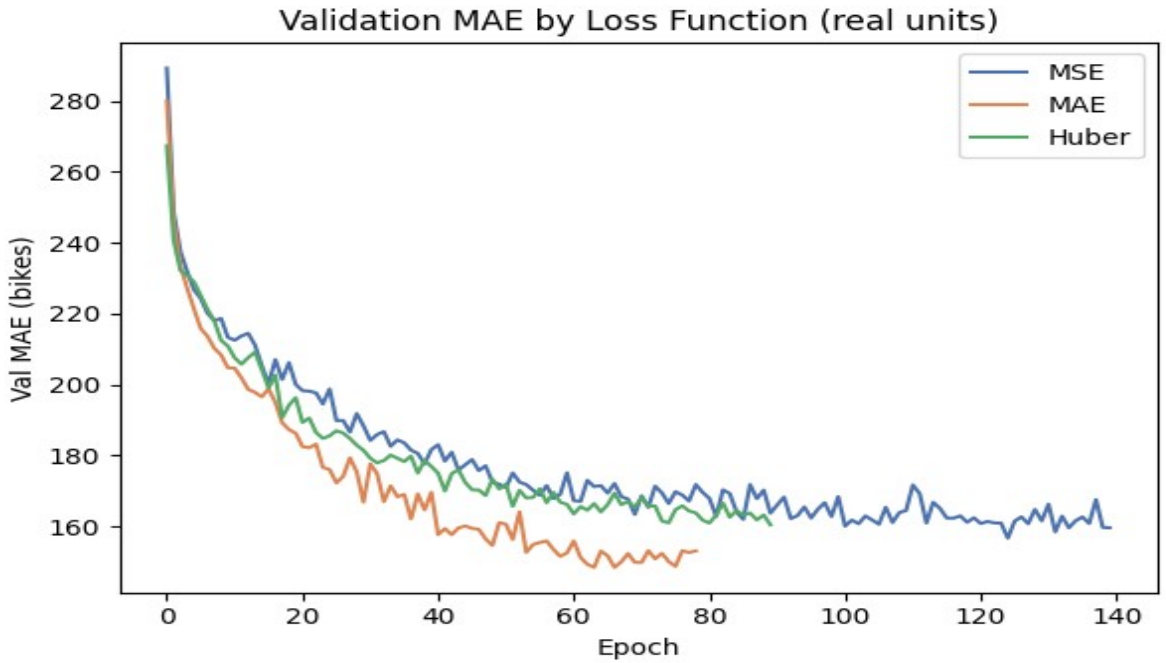
표 읽는 법 *Test MAE·RMSE 는 낮을수록 정확 (단위: 건/ 시간) · Val-Train MAE 격차 = 검증 오차 – 훈련 오차 → 클수록 (+) 과적합, 0 이하면 안정적*

구분	Test MAE (평균 오차)	Test RMSE (큰 오차 민감)	Val-Train MAE 격차 (과적합 여부)
Baseline (정규화만)	172.6 건	259.2 건	**+49.6 건 (과적합 발생)**
Dropout+EarlyStopping (개선 모델)	**166.7 건**	260.0 건	**–18.2 건 (과적합 해소)**

3. 손실함수 실험

손실함수 비교 실험 : MSE vs MAE vs Huber

동일한 Dropout+EarlyStopping 구조에서 손실함수만 교체



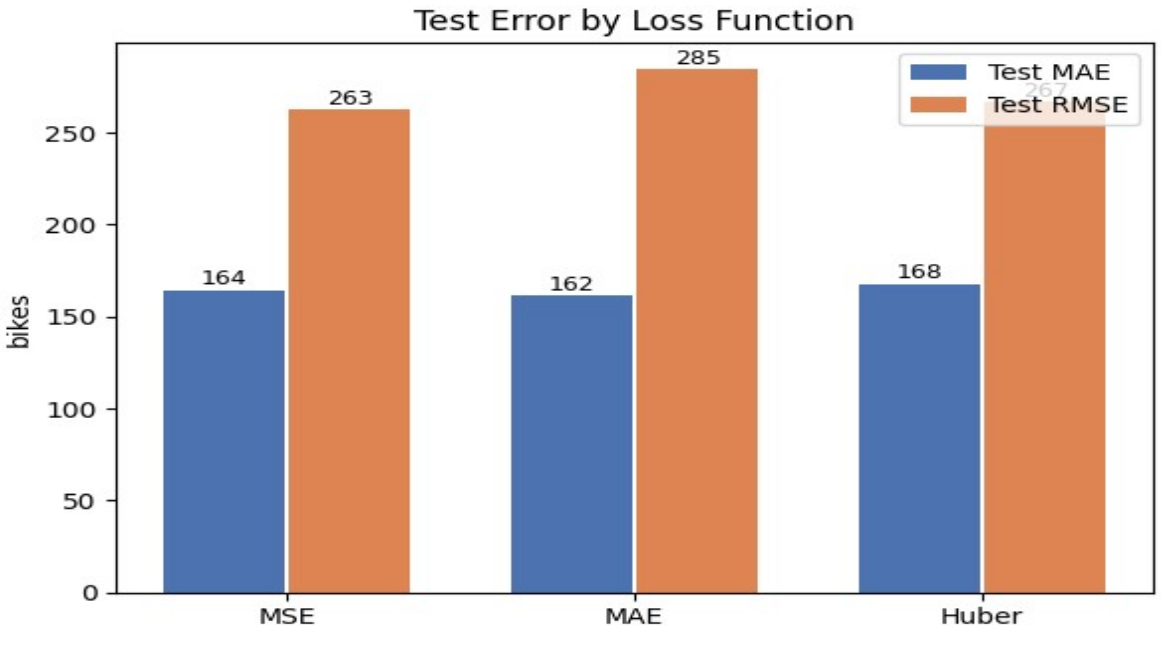


표 읽는 법 *중단 epoch = EarlyStopping 이 학습을 멈춘 시점 (괄호: 검증 오차가 가장 낮았던 시점) · MAE 낮을수록 평균 오차 작음 , RMSE 낮을수록 큰 오차 (피크 수요) 적음*

손실함수	중단 epoch (최적 시점)	Test MAE (평균 오차)	Test RMSE (큰 오차 민감)
MSE	140 (best 125)	164.4 건	262.7 건
MAE	79 (best 64)	**161.5 건**	284.5 건
Huber (δ=1.0)	90 (best 75)	167.8 건	266.7 건

종합 요약

실험 결과 종합 요약

표 읽는 법 *위 2 개 행 = 과적합 방지 실험 (목표 2·3), 아래 3 개 행 = 손실함수 실험 (목표 4, 모두 개선 모델과 동일 구조) · 초록 굵게 = 각 지표 최적값*

실험	모델 구성	Test MAE	Test RMSE	비고
① Baseline (목표 2)	Dense(64,32) + MSE	172.6 건	259.2 건	150 epoch 고정 학습 → 과적합 관찰
② 개선 모델 (목표 3)	① + Dropout(0.2) + EarlyStopping	**166.7 건**	260.0 건	86 epoch 조기 종료 → 과적합 해소
③ 손실함수 비교 (목표 4) — 아래 3 개 실험은 ②와 동일한 구조에서 손실함수만 교체				
MSE	② 와 동일	164.4 건	262.7 건	이상치 (큰 오차) 에 민감 — 오차를 제곱해서 벌점
MAE	② 와 동일	**161.5 건**	284.5 건	평균 오차 최저 , 대신 큰 오차엔 취약
Huber (δ=1.0)	② 와 동일	167.8 건	266.7 건	MSE·MAE 의 절충 (평소엔 MAE, 큰 오차엔 MSE 처럼)

결론 : Dropout+EarlyStopping 은 과적합을 확실히 줄였고 , 손실함수는 목적에 따라 선택이 달라짐 — 평균 오차를 줄이려면 MAE, 큰 오차 (피크 수요) 에 민감하게 반응하려면 MSE/Huber 가 유리 .

4. AI 도구 활용

AI 도구 활용 내역

Claude (Anthropic) · Cowork 모드

진행 방식

데이터셋 (csv) 과 과제 안내 PDF 를 Claude 에 첨부하고 , 진행 중간중간 결과물을 검토하며 방향을 직접 조정함 .

1. "PPT 를 만들어야 하는데 뭐부터 하는게 좋을까 ?" → 진행 방향 확인
2. " 전체 분석 실행 후 PPT 제작" 선택 → 전처리 ~ 실험 전체 범위를 직접 결정
3. (전처리 → 기본 MLP → Dropout/EarlyStopping 비교 → 손실함수 비교 실행)
4. " 표에 대한 설명이 부족하고 난잡해 보인다" → 결과물 검토 후 가독성 개선 요청
5. " 차별점을 주려면 프롬프트에 뭘 입력하면 좋을까" → 요구사항 이상의 심화 방향 고민

AI 활용의 장점과 유의점

장점

· 75 분이라는 짧은 시간 내 전처리 · 모델링 ·4 가지 비교 실험 · 슬라이드 제작까지 완료
· 반복적인 실험 (손실함수 3 종 비교 등) 을 빠르게 자동 실행

유의점 (직접 검토 · 판단한 부분)

· 결과 해석 (과적합 여부 , 손실함수 선택 기준) 은 직접 검토 후 확정
· 1 차 슬라이드의 표가 설명 부족 · 난잡하다고 판단 , 가독성 개선을 재요청
· 과제 요구사항 충족에 그치지 않고 , 추가로 다룰 심화 실험 방향을 직접 구상

결론

결론 및 배운 점

✓

전처리의 중요성

범주형 원 - 핫 인코딩과 수치형 (+ 목표변수)
정규화는 MLP 의 학습 속도와 안정성에 직접적인 영향을 줌 .

✓

과적합은 눈에 보인다

train/val loss 곡선의 간격만으로도 과적합을 진단할 수 있고 , Dropout+EarlyStopping 으로 간단히 완화 가능 .

✓

손실함수는 목적에 따라 선택

MAE 는 평균 오차에 강하고 , MSE/Huber 는 큰 오차 (피크 수요) 에 더 민감하게 반응함 .

처음 다뤄보는 데이터셋이라도 , 체계적인 전처리 → 베이스라인 → 개선 → 비교 실험의 흐름을 따르면 짧은 시간 안에도 신뢰할 수 있는 딥러닝 모델링이 가능하다는 것을 확인했습니다 .